

Big Data aplicado a la seguridad ciudadana y vial de Nueva York: diagnóstico territorial y plan de acción

Entrega 1: entendimiento del negocio y entendimiento de los datos

Estudiantes: Nikholas Barsky Angulo y Laura Zoet Guacaneme Gómez

Pontificia Universidad Javeriana
Facultad de Ingeniería, Departamento de Ingeniería de Sistemas

Procesamiento de Datos a Gran Escala, clase 1255
Profesor: John Corredor Franco, PhD

6 de octubre de 2026
Bogotá D.C., Colombia

1. Entendimiento del negocio

El proyecto sigue la metodología CRISP-DM, que organiza el trabajo en seis fases: entendimiento del negocio, entendimiento de los datos, preparación, modelado, evaluación e implantación (Corredor Franco, 2026). Esta entrega cubre las dos primeras fases y deja un avance de la tercera; el modelado con MLlib y el plan de acción quedan para la entrega final.

1.1 Contexto

Nueva York es la ciudad más poblada de Estados Unidos, con 8,478,238 habitantes según ACS PUMS 2024 (U.S. Census Bureau, s.f.), repartidos en cinco distritos o *boroughs* muy distintos entre sí. El 18.15% de su población vive bajo la línea federal de pobreza, y en el Bronx la cifra llega al 28.96%. El gobierno considera prioritarios los arrestos y los choques de tránsito, que se concentran en ciertas zonas y horas. La ciudad cuenta además con dos servicios que pueden apoyar un plan de acción: los centros públicos de computadores, en una ciudad donde más de 1.5 millones de personas no tenían internet en casa ni en el celular (NYC Mayor's Office of the CTO, 2020), y los parques, medidos con la meta de 2.5 acres de espacio abierto por cada 1,000 residentes (Mayor's Office of Environmental Coordination, 2021). Por eso el diagnóstico baja de los distritos a las 55 PUMAs, zonas del censo de 93,000 a 266,000 habitantes (Tabla1).

Indicador	Valor	Fuente
Población de la ciudad	8,478,238 en 2024; 8,390,888 según el Estado en 2023	U.S. Census Bureau (s.f.); NYSDOH (s.f.)
Pobreza federal	18.15% en 2024; Bronx 28.96% y Staten Island 11.19%	ACS PUMS 2024, cálculo propio
Desempleo	6.97% en 2024; 15.25% en jóvenes de 16 a 24 años	ACS PUMS 2024, cálculo propio
Arrestos	278,953 en 2025, un 79.4% más que en 2021	NYC Open Data (s.f.-b)
Choques de tránsito	524,338 entre 2021 y el 11 de junio de 2026; 1,364 muertos en 2021-2025	NYC Open Data (s.f.-c)
SAT de bachillerato	907.8 de 1,600 por colegio en 2024-25; media del estado 1,035	NYC DOE (s.f.); College Board (2024)
Brecha digital	18% de la población sin internet en casa ni en el celular	NYC Mayor's Office of the CTO (2020)
Espacio público	Meta de 2.5 acres por 1,000 residentes, 2.0 activos; la ciudad tiene 3.19 y 0.66	Mayor's Office of Env. Coordination (2021)

Tabla1. Indicadores socioeconómicos y territoriales de interés para la ciudad de Nueva York

1.2 Objetivo de negocio

El gobierno quiere reducir el volumen de arrestos y los choques de tránsito con víctimas. El objetivo del equipo consultor es **construir, con datos públicos de seguridad, tránsito, condiciones sociales, educación, acceso digital y espacio público, un diagnóstico territorial por distrito y por PUMA que identifique zonas críticas, patrones temporales y factores asociados a cada indicador, para sustentar un plan de acción basado en evidencia.** El proyecto será exitoso si logra priorizar pocas PUMAs, franjas horarias y tipos de delito o de choque, comparar todas las zonas con la misma población de referencia y responder las 10 preguntas de la sección 6 sin afirmar causas que los datos no permiten probar.

2. Selección de los datos a utilizar

Se seleccionaron 12 fuentes oficiales para 2021-2026 (Tabla2). No se usan NYCgov 2018, el SAT de 2012 ni PUMS 2018, porque hay datos más recientes y el enunciado permite cambiar los conjuntos de datos; en

su lugar se usan PUMS 2024 y el SAT de 2023-25, y se suman Person, los centros de computadores, los parques y las PUMAs para analizar por distrito y por PUMA.

Fuente	Años	Nivel	Rol
NYPD Arrest Data YTD y Historic (NYC Open Data, s.f.-a, s.f.-b)	2021-2026	Distrito y PUMA	Primer indicador: arrestos
Motor Vehicle Collisions: Crashes, Vehicles y Person (NYC Open Data, s.f.-c, s.f.-d, s.f.-e)	2021-2026	Distrito y PUMA	Segundo indicador: choques, vehículos, causas y víctimas
ACS PUMS personas (U.S. Census Bureau, s.f.)	2024	Distrito y PUMA	Población, pobreza, desempleo y educación; denominador de las tasas
School Quality Reports, SAT (NYC DOE, s.f.)	2023-24 y 2024-25	Distrito	Desempeño educativo
Public Computer Centers (NYC Open Data, s.f.-f)	2026	Distrito y PUMA	Acceso digital público
Parks Active and Passive Recreation (NYC Open Data, s.f.-g)	2026	Distrito y PUMA	Espacio público según el manual CEQR
Límites de las PUMAs 2020 (NYC Open Data, s.f.-h)	2020	PUMA	Ubicar puntos y dibujar mapas
Población NYSDOH, web scraping (NYSDOH, s.f.)	2023	Distrito	Validar la población, Bono 1
OpenWeatherMap, API (OpenWeather, s.f.)	Tiempo real	Ciudad	Contexto climático, Bono 2

Tabla2. Fuentes seleccionadas, periodo, nivel geográfico y rol en el proyecto

Por qué estas fuentes. Arrestos y choques son los dos indicadores que el gobierno quiere bajar. Crashes da el lugar, la hora y las víctimas; Vehicles el tipo de vehículo y la causa; y Person quién resultó herido o muerto. PUMS aporta la población de todas las tasas y las condiciones sociales; el SAT mide la educación de los jóvenes; y los centros y los parques son servicios que el plan puede reforzar. Los choques empiezan en 2021 porque desde abril de 2020 la NYPD no registra los choques que solo dejan daños materiales, así que todo el periodo tiene un único régimen de registro. La Fig1 muestra el recorrido de cada fuente. **Limitaciones:** las tasas de Manhattan están infladas por la gente que trabaja o visita allí sin vivir allí; con cinco distritos los cruces son pistas y por PUMA siguen siendo exploratorios; y PUMS tiene margen de error por PUMA.

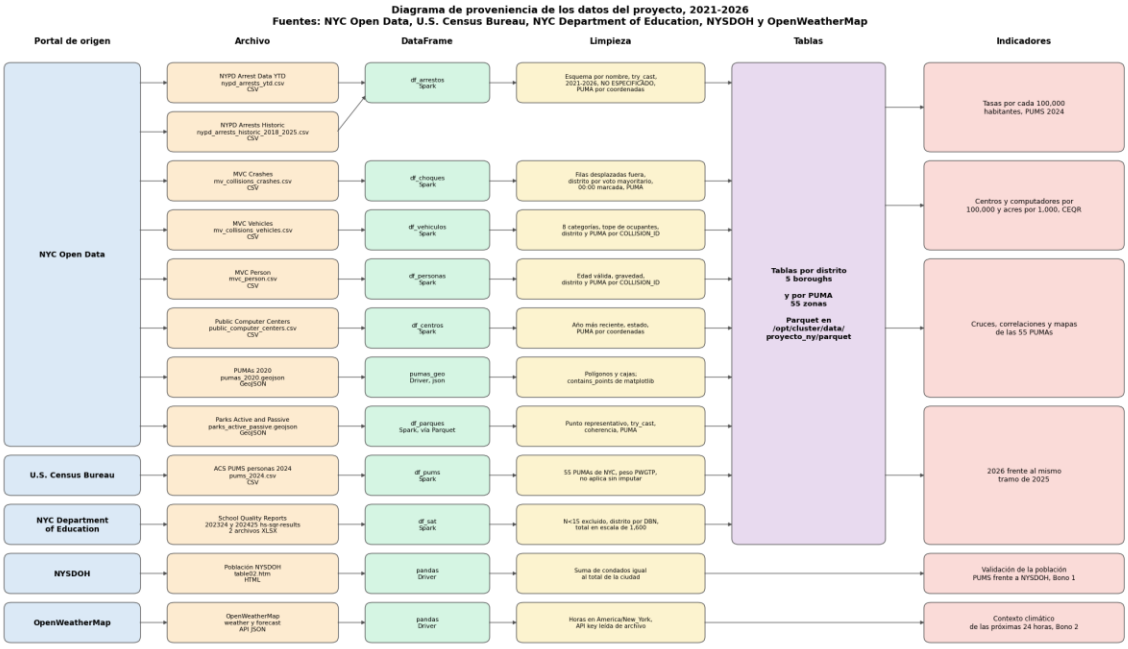


Fig1. Diagrama de proveniencia de los datos: portal, archivo, DataFrame de Spark, limpieza, tablas por distrito y por PUMA e indicadores

3. Colección y descripción de los datos

El procesamiento se ejecuta en un clúster **Apache Spark en modo Standalone** de la Nube Privada de la Javeriana (Tabla3): el *Driver* coordina la aplicación y el *cluster manager* reparte las tareas entre los *executors* de los workers (Corredor Franco, 2024; The Apache Software Foundation, s.f.). Las transformaciones son perezosas y solo se ejecutan con una acción, como count. Los datos están en una carpeta compartida por **NFS** y no en HDFS, una limitación de la infraestructura. Como el Driver usa Python 3.9 y Spark 4.2 pide 3.10, los workers no ejecutan código Python y todo el procesamiento distribuido usa funciones nativas de Spark SQL. Las bases limpias se guardan en Parquet.

Parámetro	**Valor**
Master y Driver	spark://10.43.97.58:7077, nodo NBDG41; Driver en NBDG44, 10.43.97.61
Versiones	Spark 4.2.0 en el clúster; PySpark 4.0.4 y Python 3.9.25 en el Driver
Recursos y configuración	Driver de 2 GB; cada ejecutor con 2 núcleos y 2 GB, porque el clúster lo comparten seis personas; 200 particiones de shuffle, ejecución adaptativa y zona horaria America/New_York
Almacenamiento	NFS en /opt/cluster/data/proyecto_ny; bases limpias en Parquet

Tabla3. Características del clúster Spark y del entorno de ejecución

Cada base se cargó con un esquema explícito: el CSV se lee como texto y cada columna se convierte por nombre con try_cast, así un texto inválido queda en NULL y se cuenta sin detener el trabajo. Solo se leen las columnas necesarias y los años se filtran al cargar; aun así se procesan cerca de 4.7 millones de registros (Tabla4).

Conjunto, filas × columnas usadas	Tipos	Atributos clave y significado
Arrestos, 1,253,479 × 14: un arresto por fila	bigint, int, double, date, string	OFNS_DESC: delito; LAW_CAT_CD: F felony, M misdemeanor, V violation; ARREST_BORO: distrito; AGE_GROUP, PERP_SEX: perfil; coordenadas
Crashes, 524,338 × 21: un choque por fila	bigint, int, double, date, string	COLLISION_ID: llave; CRASH_DATE, CRASH_TIME; BOROUGH; NUMBER_OF_PERSONS_INJURED y KILLED; coordenadas
Vehicles, 1,057,393 × 11: un vehículo por fila	bigint, int, string, date	VEHICLE_TYPE, en 8 categorías; VEHICLE_OCCUPANTS; CONTRIBUTING_FACTOR_1: causa
Person, 1,820,886 × 17: una persona por fila	bigint, int, string, date	PERSON_TYPE: peatón, ciclista, ocupante; PERSON_INJURY: herido o muerto; PERSON_AGE; BODILY_INJURY
PUMS 2024, 67,511 × 9: una persona de la muestra	int, string	PUMA; PWGTP: peso; POVPIP: ingreso frente a la línea de pobreza; ESR: empleo; SCHL: educación
SAT, 1,014 × 4: un colegio por curso	string	DBN: el 3.er carácter es el distrito; Math y Reading and Writing; N<15 = suprimido
Centros, 974 × 10; parques, 2,936 × 18	int, double, string	Centros: STATUS, WORKSTATION_NUMBER y coordenadas. Parques: ACRES, ACTIVE_ACRES, TYPE_CATEGORY y un punto representativo del polígono

Tabla4. Volumen, tipos de datos, significado de los atributos y descripción general de los conjuntos de datos

4. Exploración de los datos

De las más de 40 tablas y gráficas del notebook, calculadas en Spark, se presentan las principales. Las tasas usan la población de PUMS 2024.

4.1 Arrestos

Los arrestos crecieron 79.4% entre 2021 y 2025, de 155,507 a 278,953, en los cinco distritos. Brooklyn tiene más arrestos, pero el Bronx tiene la mayor tasa: 4,534.6 por cada 100,000 habitantes, frente a 3,290.2 de la ciudad. Por PUMA la tasa va de 690 a 9,841, y la más alta, la PUMA 4221 del Bronx, es también la más pobre de la ciudad (Fig2); por eso el plan debe focalizarse por PUMA.

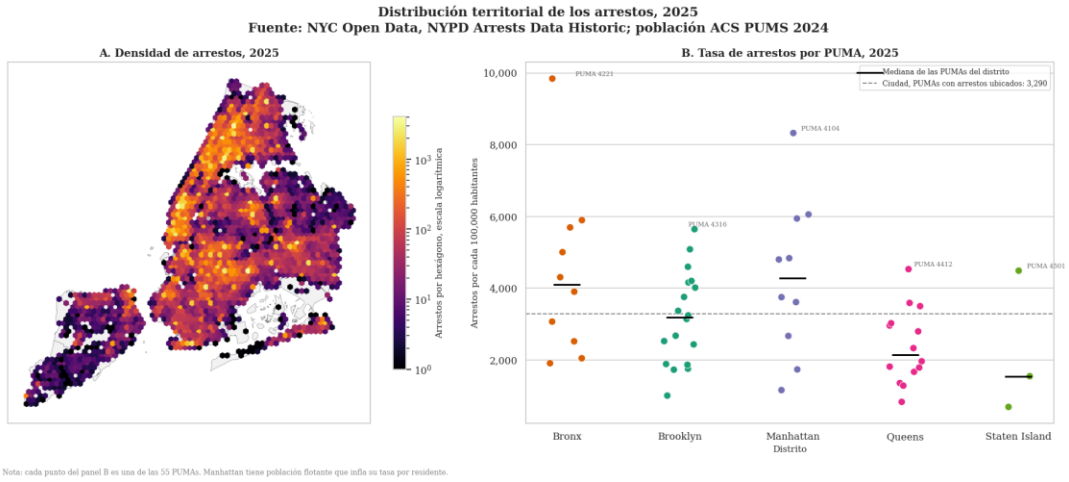


Fig2. Densidad de los arrestos de 2025 y tasa de arrestos por PUMA dentro de cada distrito

Trece de las 62 categorías de delito explican el 80.43% de los arrestos de 2025, encabezadas por *Assault 3*, agresión menor, con 14.24%, y *Petit Larceny*, robo menor, con 9.93% (Fig3). Entre 2021 y 2025 los arrestos por drogas y por robo menor más que se duplicaron. En los menores de 18 años el 69.2% de los arrestos es por delito grave, *felony*; los hombres son el 82.1% de los arrestos, y entre semana hay 29.8% más arrestos por día que el fin de semana.

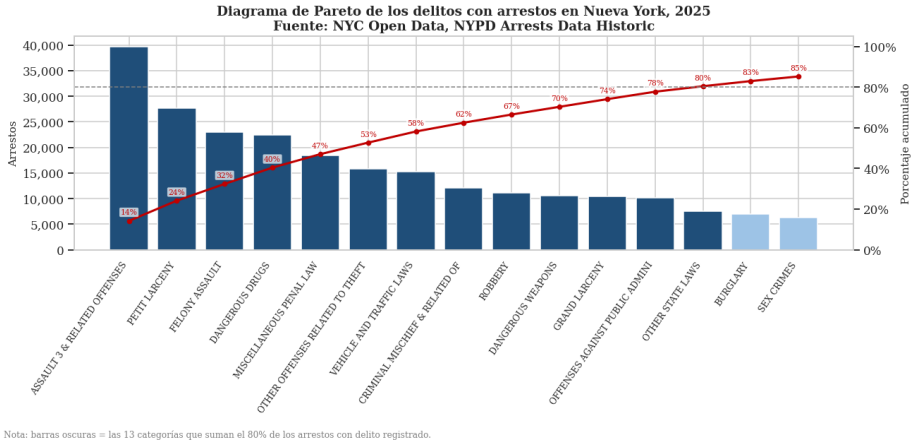


Fig3. Diagrama de Pareto de los delitos con arrestos en 2025

4.2 Choques, vehículos y víctimas

Entre 2021 y 2025 hubo 487,914 choques; el 40.2% dejó víctimas, con 261,634 heridos y 1,364 muertos. Brooklyn tiene la mayor tasa de choques con víctimas, 475.35 por cada 100,000 habitantes en 2025. Las motos aparecen en choques mortales 7.5 veces más que los sedanes. La distracción es la causa más común, 33.11%, pero en los choques mortales pesan más la velocidad insegura, que pasa de 4.82% a 23.90%, y no respetar el semáforo, de 3.77% a 11.33% (Fig4). El pico es entre semana de 14:00 a 18:00, con el máximo el viernes a las 17:00.

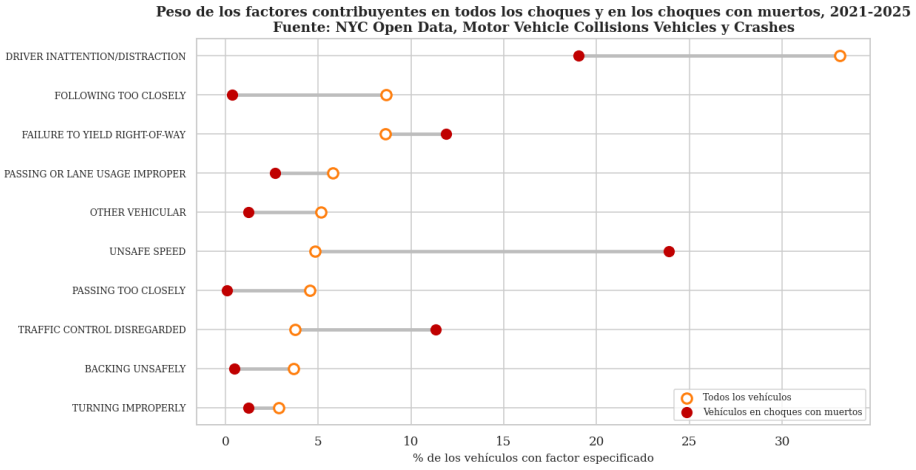


Fig4. Peso de los factores contribuyentes en todos los vehículos y en los de choques con muertos, 2021-2025

Person muestra que los peatones son el 16.93% de los heridos pero el 45.23% de los muertos, con una letalidad 4.4 veces mayor que la de los ocupantes. Su peso en los muertos subió de 44.4% en 2021 a 52.0% en 2025 (Fig5), y la mitad de los peatones que mueren tiene 58 años o más.

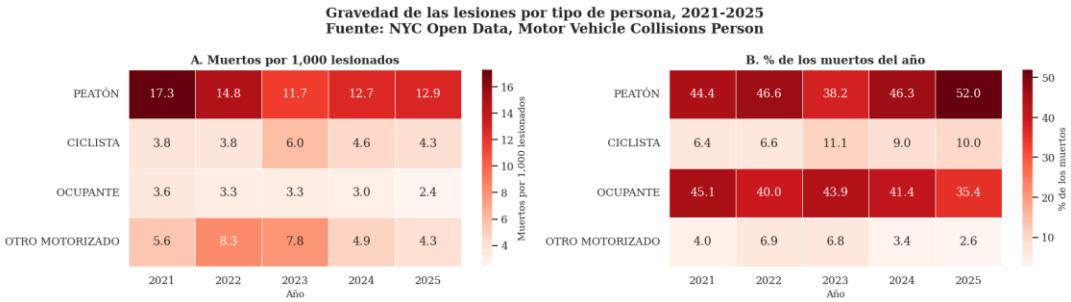


Fig5. Muertos por cada 1,000 lesionados y porcentaje de los muertos del año por tipo de persona, 2021-2025

4.3 Condiciones sociales, educación, acceso digital y espacio público

El Bronx tiene la mayor pobreza, 28.96%, el mayor desempleo, 10.48%, y el menor SAT, 850.8 puntos, frente a 1,020.6 de Staten Island; en todos los distritos la mediana de los colegios está por debajo de la media del estado, 1,035. Dentro de cada distrito hay zonas muy distintas: en el Bronx la pobreza va de 11.92% a 43.77% entre PUMAs. Hay 515 centros públicos de computadores, 71.47 computadores por cada 100,000 habitantes, y Brooklyn tiene la menor oferta, 52.10. En espacio público, después de dejar una fila por parque, la ciudad tiene 3.19 acres por cada 1,000 habitantes, por encima de la meta de 2.5, pero solo 0.66 de recreación activa, un tercio de la meta de 2.0. Ningún distrito cumple la meta activa: Manhattan tiene 0.36 y Brooklyn 0.54. Por PUMA, 52 de las 55 están por debajo de la meta activa, así que la recreación activa es el punto más débil del espacio público.

4.4 Cruces por distrito y por PUMA

Por distrito, con n = 5, los arrestos se relacionan con la pobreza, r = 0.83, y con el SAT en sentido contrario, r = −0.57, mientras que los choques con víctimas casi no se relacionan con la pobreza, r = 0.23; con 5 datos son pistas. Por PUMA, con n = 55, la relación entre arrestos y pobreza se mantiene, r = 0.51, y sube a 0.70 sin Manhattan (Fig6). Los choques con víctimas no se relacionan con la pobreza, r = 0.03, así que los dos indicadores necesitan estrategias distintas. Los peatones y ciclistas lesionados se asocian con menos acres de recreación activa, r = −0.34. Los mapas (Fig7) muestran que los arrestos se concentran en el sur del Bronx y en Manhattan, y los choques con víctimas en el este de Brooklyn y el sureste de Queens.

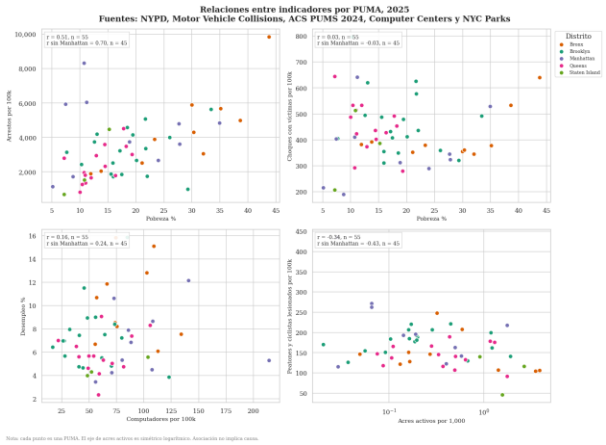


Fig6. Relaciones entre indicadores por PUMA, 2025

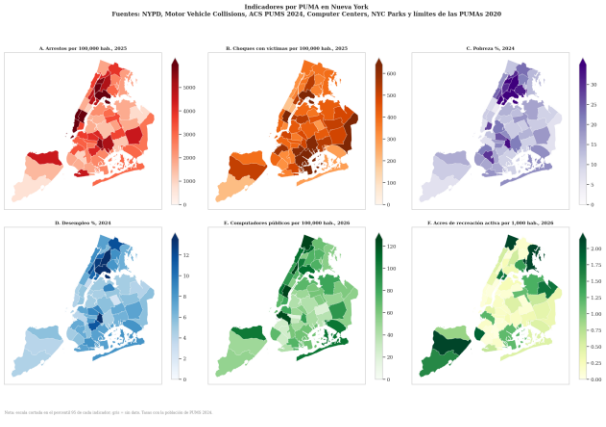


Fig7. Indicadores por PUMA: arrestos, choques con víctimas, pobreza, desempleo, computadores y recreación activa

4.5 Lo más reciente y bonos

Del 1 de enero al 11 de junio de 2026, frente a las mismas fechas de 2025, la ciudad casi no cambia: los arrestos bajan 0.9% y los choques con víctimas 1.5%. El Bronx es la excepción: sube en arrestos, 2.4%, en choques con víctimas, 9.8%, y en heridos, 15.6%. Los muertos de 2026 no se comparan porque 8,877 choques de 2026 no traen ese dato. En el Bono 1 se leyó por web scraping la población del NYSDOH de 2023, 8,390,888, que difiere solo 1.03% de PUMS 2024 y valida el denominador. En el Bono 2 la API de OpenWeatherMap dio 18.06 °C y cielo claro el 19 de octubre de 2026, y un pronóstico de 24 horas sin lluvia; en la entrega final se cruzará el clima histórico con los choques.

5. Reporte de calidad de los datos

Los faltantes se contaron por columna y por año en una sola pasada por base. Casi ninguno es al azar: unos campos no aplican a todos los registros y otros faltan en un solo año, así que no se imputa con la media ni con el valor más común (Tabla5).

Base	Faltante principal	Causa	Técnica propuesta
Arrestos	Edad y sexo: 52.78% en 2025; nivel del delito 0.68%	Vacío de un año; omisiones	"NO ESPECIFICADO"; perfiles con 2021-2024 y 2026
Crashes	Distrito 29.77%; coordenadas 6.36%; muertos 24.37% en 2026; hora 00:00 en 1.6% a 2.1%	No diligenciado; dato incompleto; hora de relleno	Distrito por voto mayoritario de su celda de 1 km²; muertos 2026 no se comparan; 00:00 sale del análisis por hora
Vehicles	Licencia 40.12%; sexo del conductor 35.61%; ocupantes imposibles	No registrados; digitación	"NO ESPECIFICADO"; tope de ocupantes por categoría
Person	PED_ACTION 97.19%; equipo de seguridad 57.82%; edad 18.00%	No aplican a todos	Análisis dentro del tipo de persona; edad de 0 a 110
PUMS y SAT	ESR 14.02%; POVPIP 3.77%; SAT N<15 en 87 y 86 colegios	No aplica; supresión	Salen del denominador; N<15 se excluye
Centros y parques	Estado 46.82%; 1,125 filas de parques repiten GISPROPNUM	Registro 2025 sin estado; partes de un parque	Se usa 2026; una fila por parque

Tabla5. Resumen de faltantes por base, causa identificada y técnica de tratamiento propuesta

Unicidad e integridad. Las llaves de arrestos, choques, vehículos, personas, PUMS y SAT son únicas y sin vacíos. Ningún vehículo ni ninguna persona apunta a un choque inexistente, y los heridos y muertos de Person coinciden al 100% con los de Crashes, así que Person es confiable aunque su actualización estuvo pausada. La excepción son los parques: 1,125 filas repetían un GISPROPNUM porque cada parte de un parque traía el área total, lo que inflaba la suma de 27,041 a 63,971 acres; por eso se deja una fila por parque.

6. Planteamiento de preguntas de negocio

Se plantean 10 preguntas medibles que se responderán en la entrega final:

1. ¿Cuáles son las 10 PUMAs con mayor tasa de arrestos en 2025 y qué porcentaje de los arrestos de la ciudad concentran?
2. ¿Cómo cambió entre 2021 y 2024 el peso de los delitos graves en los menores de 25 años, y se mantiene en 2026?
3. ¿Qué tan fuerte es la relación entre pobreza y arrestos en las 55 PUMAs, y se mantiene sin Manhattan?
4. ¿En qué franjas de día y hora se concentran los choques con víctimas y cambian entre distritos?

5. ¿Qué tipo de persona tiene la mayor letalidad y en qué distritos y edades es más alta?
6. ¿Qué vehículos y factores pesan más en los choques con muertos que en el total?
7. ¿Qué PUMAs superan el percentil 75 en arrestos y en choques con víctimas, y cuáles suben en 2026?
8. ¿Las PUMAs con menos computadores públicos por habitante tienen más pobreza, desempleo y arrestos?
9. ¿Las PUMAs por debajo de la meta CEQR de recreación activa tienen más peatones y ciclistas lesionados?
10. ¿Los distritos con menor SAT tienen más desempleo juvenil y más arrestos de menores de 25 años?

7. Filtros, limpieza y transformación inicial

La Tabla6 resume lo aplicado. Ninguna limpieza borró registros de arrestos, choques, vehículos ni personas: los valores imposibles pasan a NULL y las categorías faltantes reciben una etiqueta.

Tipo	Operación	Resultado
Filtro	Periodo 2021-2026 al cargar; PUMS solo con las 55 PUMAs de la ciudad	Crashes de 2,269,188 a 524,338 filas; Person de 5,984,110 a 1,820,886
Filtro	Una fila por GISPROPNUM en parques, porque las partes de un parque repiten su área	De 2,936 filas a 1,811 parques; acres de 63,971 a 27,041
Limpieza	Tope de ocupantes por categoría de vehículo	111 valores pasan a NULL, el 0.01%
Limpieza	Distrito de los choques por voto mayoritario de su celda	Sin distrito de 29.77% a 5.34%; consistencia de 99.32%
Transformación	8 categorías de vehículo; tipo de persona, gravedad y grupos de edad en español	Vehículos y personas listos para comparar
Transformación	Asignación a PUMA por coordenadas, contains_points y broadcast join	PUMA en el 99.99% de los arrestos y el 92.14% de los choques
Transformación	Tasas por cada 100,000 habitantes y acres por cada 1,000 con PUMS 2024	Tablas de indicadores en Parquet: 5 distritos y 55 PUMAs

Tabla6. Avance de filtros, limpieza y transformaciones aplicados a los datos

Referencias

College Board. (2024). *New York SAT suite of assessments annual report 2024*. https://reports.collegeboard.org/media/pdf/2024-new-york-sat-suite-of-assessments-annual-report-ADA.pdf

Corredor Franco, J. (2024). *Procesamiento de datos a gran escala: Big Data* [Diapositivas de clase]. Pontificia Universidad Javeriana.

Corredor Franco, J. (2026). *Conceptos Big Data: Metodología CRISP-DM* [Diapositivas de clase]. Pontificia Universidad Javeriana.

Mayor's Office of Environmental Coordination. (2021). *CEQR technical manual, chapter 7: Open space*. https://www.nyc.gov/assets/oec/technical-manual/07_Open_Space_2021.pdf

New York State Department of Health. (s.f.). *Vital statistics of New York State 2023, table 2*. https://www.health.ny.gov/statistics/vital_statistics/2023/table02.htm

NYC Department of Education. (s.f.). *School quality reports 2023-24 y 2024-25*. https://infohub.nyced.org/reports/school-quality/school-quality-reports-and-resources

NYC Mayor's Office of the Chief Technology Officer. (2020, 7 de enero). *Internet Master Plan* [Comunicado de prensa]. https://www.nyc.gov/office-of-the-mayor/news/010-20/de-blasio-administration-releases-internet-master-plan-city-s-broadband-future

NYC Open Data. (s.f.-a). *NYPD arrest data (year to date)*. https://data.cityofnewyork.us/d/uip8-fykc

NYC Open Data. (s.f.-b). *NYPD arrests data (historic)*. https://data.cityofnewyork.us/d/8h9b-rp9u

NYC Open Data. (s.f.-c). *Motor vehicle collisions: Crashes*. https://data.cityofnewyork.us/d/h9gi-nx95

NYC Open Data. (s.f.-d). *Motor vehicle collisions: Vehicles*. https://data.cityofnewyork.us/d/bm4k-52h4

NYC Open Data. (s.f.-e). *Motor vehicle collisions: Person*. https://data.cityofnewyork.us/d/f55k-p6yu

NYC Open Data. (s.f.-f). *Citywide public computer centers*. https://data.cityofnewyork.us/d/sejx-2gn3

NYC Open Data. (s.f.-g). *NYC Parks active and passive recreation*. https://data.cityofnewyork.us/d/kcqe-vnci

NYC Open Data. (s.f.-h). *2020 Public Use Microdata Areas (PUMAs)*. https://data.cityofnewyork.us/d/pikk-p9nv

OpenWeather. (s.f.). *Weather API*. https://openweathermap.org/api

The Apache Software Foundation. (s.f.). *Spark standalone mode*. https://spark.apache.org/docs/latest/spark-standalone.html

U.S. Census Bureau. (s.f.). *American Community Survey 2024 Public Use Microdata Sample*. https://www.census.gov/programs-surveys/acs/microdata.html